

О проекте

Для работы был использован открытый датасет с набором транзакционных данных британской онлайн-розничной компании, за период с 01.12.2010 по 09.12.2011:

<https://archive.ics.uci.edu/dataset/352/online%2Bretail>

Компания специализируется на продаже подарочной продукции. Многие клиенты компании являются оптовиками.

Цели проекта:


1. Выявить потенциальные точки роста бизнеса;
2. Определить закономерности, которые позволят увеличить выручку;
3. Определить факторы, негативно влияющие на выручку;
4. Сегментировать клиентов на группы и выявить какой тип клиентов приносит основную выручку;
5. Проанализировать отмененные заказы и их уровень влияния на выручку.

Подготовка данных

Помимо транзакционных данных, необходимых для анализа, в датасете были обнаружены данные о скидках, перевозках, комиссиях, подарочных купонах, почтовых доставках, ручные записи и т.д.

Так как изначально не стояло цели проанализировать влияние этих категорий, они были исключены из анализа.

Также, в процессе обработки данных были обнаружены записи с выбросами, четыре из которых выглядели подозрительно, даже с учетом того, что компания работает с оптовыми клиентами:



InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
61619	541431	23166 MEDIUM CERAMIC TOP STORAGE JAR	74215	2011-01-18 10:01:00	1.04	12346.0	United Kingdom
61624	C541433	23166 MEDIUM CERAMIC TOP STORAGE JAR	-74215	2011-01-18 10:17:00	1.04	12346.0	United Kingdom
540421	581483	23843 PAPER CRAFT , LITTLE BIRDIE	80995	2011-12-09 09:15:00	2.08	16446.0	United Kingdom
540422	C581484	23843 PAPER CRAFT , LITTLE BIRDIE	-80995	2011-12-09 09:27:00	2.08	16446.0	United Kingdom

Рисунок 1. Выбросы

Два заказа были отменены менее, чем через 20 минут после оформления. Для корректного анализа эти записи были исключены из датасета

Помимо четырех подозрительных записей, в датасете присутствует большое количество иных выбросов, но с учетом того, что компания работает как с оптовыми, так и с розничными клиентами, исключать эти выбросы нецелесообразно.

Например, на рисунке 2 отчетливо можно увидеть выброс Quantity outliers в районе -9700. Большая часть этого товара (9360 единиц), была отменена одним клиентом, но этот же клиент, сделал еще 167 заказов, которые многократно перекрыли отмену




Рисунок 2. Выбросы

Анализ динамических показателей

Так как данные за 12.2011 неполные, декабрь не рассматривался во время анализа показателей выручки




Рисунок 3. Общая месячная выручка и месячная выручка на пользователя

На верхнем графике показана ежемесячная выручка, где можно наблюдать четыре основных момента:

1. Падение выручки с декабря 2010 по февраль 2011;
2. Падение выручки в апреле 2011;
3. Рост выручки с августа по ноябрь 2011;
4. Двукратная разница между выручкой декабря 2010 и ноября 2011.

На нижнем графике показана ежемесячная выручка на пользователя, где можно наблюдать:

1. Падение выручки с января 2010 по февраль 2011;
2. Значительное падение выручки в апреле 2011;
3. Рост выручки с июля по сентябрь 2011;
4. Падение выручки с октября по ноябрь.

Сразу стоит оговориться, что падение в апреле связано с техническими причинами - этот месяц содержит наименьшее число отчетных дней за весь период 2011 года.




Рисунок 4. Количество отчетных дней за каждый месяц

На основе графиков, представленных выше, можно сделать предположение, что бизнес имеет осенне-предновогоднюю сезонность, где начиная с конца лета идет рост выручки, достигая максимума в ноябре-декабре, а начиная с января идет охлаждение рынка, после чего он восстанавливается и с весны по осень находится в стабильном состоянии.

Ту же самую тенденцию можно наблюдать на графике с количеством уникальных пользователей за месяц - с декабря по февраль их число падает, далее до сентября остается стабильным, после чего наблюдается резкий рост.




Рисунок 5. Количество уникальных пользователей за каждый месяц

Помимо этого стоит упомянуть рост выручки в 1.88 раз в ноябре 2011, по сравнению с декабрем 2010 и сопоставимый рост числа уникальных пользователей, что говорит об активном росте клиентской базы.

Исходя из полученной информации можно выдвинуть следующие гипотезы:

1. В период с августа по декабрь выручка растет более чем на 50%, по сравнению с выручкой за период с марта по август;
2. В период с августа по декабрь число проданных товаров, связанных с новым годом и рождеством растет более чем на 50%, по сравнению с выручкой за период с марта по август;
3. В период с августа по октябрь число проданных канцелярских товаров и школьных принадлежностей растет более чем на 20%, по сравнению с выручкой за период с ноября по август.

В случае принятия первой гипотезы, можно будет проанализировать какие именно товары чаще покупают осенью и зимой.

В случае принятия второй гипотезы, можно будет сместить на новогодние товары и провести A/B тестирования для оценки эффективности.

В случае принятия третьей гипотезы, можно будет разработать план продаж в период back to school.

Анализ пользовательского поведения

В рамках когортного анализа не было выявлено каких-либо четких закономерностей, позволивших бы сделать выводы о поведении пользователей в рамках разбиения на когорты.

Можно отметить, что лучший коэффициент удержания имеет первая когорта - 12.2010, но с учетом того, что нет данных за предыдущие периоды, нельзя отрицать, что это может быть уже сформировавшаяся когорта из старых, лояльных клиентов компании. Также можно заметить, что на второй месяц жизни, все когорты, кроме первой, теряют 75-85% аудитории. Но затем, за исключением когорт 04.2011 и 05.2011, на третий-четвертый месяц жизни наблюдается рост retention, что позволяет сделать предположение о том, что часть клиентов совершает покупки раз в 2-4 месяца




Рисунок 6. Тепловая карта. Когортный анализ

Значительная часть клиентов делает только один заказ, но при этом доля выручки от таких клиентов составляет лишь 6.5% от всей выручки





Рисунок 7. Доли количества заказов и доли выручки

Для повышения выручки, стоит провести подробный анализ клиентов, совершивших одну покупку. Это могут быть как розничные клиенты, так и оптовые, которые по каким-то причинам не вернулись после совершения первой покупки - например, нашли лучшие условия у конкурентов.

Работа с такими клиентами и перевод их из сегмента клиентов с разовыми покупками в сегмент лояльных клиентов может значительно повысить выручку.

Сегментация пользователей

Для сегментации клиентов было использовано два метода: RFM анализ и кластеризация на основе машинного обучения

В процессе RFM анализа были выявлены следующие сегменты клиентов:

- Топовые - покупают часто и на большие суммы;
- Лояльные - постоянно делают покупки;
- Потенциально лояльные - совершившие несколько покупок за ближайшее время;
- Новые - недавно совершили первую покупку;
- Спящие - совершали покупки, но последняя была сделана давно;
- Потерянные - совершили только одну покупку и сделали ее давно;
- В зоне риска - клиенты, которые рискуют быть потерянными;
- Другие - клиенты, не попавшие ни в один из сегментов.




Рисунок 8. RFM сегментация клиентов

Можно выделить два сегмента, генерирующих основную часть выручки - лояльные клиенты и топ-клиенты, что согласуется с предыдущим анализом пользовательского поведения.

При этом доля сегмента потерянных клиентов вторая по величине, что косвенно может говорить о плохо настроенной работе с клиентами в зоне риска.

Спящие клиенты также являются значительной долей клиентов, но с учетом предновогодней сезонности бизнеса и максимальным разрывом между покупками в 366 дней, нельзя с уверенностью сказать о том что этот сегмент является проблемным

На основе RFM сегментации стоит дополнительно провести подробный анализ потерянных клиентов и клиентов в зоне риска - какие товары они покупали, в каком количестве, в какой период совершили покупку, как часто делали отмены. Это позволит составить более подробный портрет этих сегментов, даст понимание методов работы с ними и позволит увеличить выручку.

Также можно выдвинуть следующую гипотезу:

- Не менее 20% клиентов из сегмента спящих возвращаются в период с августа по декабрь.

В случае принятия этой гипотезы, можно будет выделить таких клиентов в отдельный сегмент, а затем провести более предметный анализ действительно спящих клиентов.

Кластеризация была выполнена с использованием алгоритма машинного обучения KMeans. На основе KMeans, оптимальным числом кластеров для разделения оказалось 2, но в этом случае все клиенты были бы разделены на две категории: лояльные и те, кто совершили одну-две покупки. Поэтому для кластеризации было выбрано второе оптимальное число кластеров - 3

	recency	frequency	monetary	avg_check	items_per_order	revenue_share	size
cluster							
0	80.0	2.0	674.68	386.420000	246.50	17.1	1545
1	95.0	1.0	216.30	151.420000	76.50	4.7	1449
2	13.0	7.0	2314.65	341.526667	199.75	78.2	1339

Рисунок 9. Кластеризация на основе KMeans

Кластеры распределились следующим образом:

- Кластер 0. Спящие клиенты. Купили > 1 раза, но последняя покупка была давно;
- Кластер 1. Случайные/разовые клиенты. Сделали одну покупку, с небольшим чеком и объемом;
- Кластер 2. Лояльные клиенты. Покупают часто, в больших объемах и приносят основную долю выручки.

При этом все кластеры имеют примерно одинаковое число клиентов, входящих в них.

Для планирования методов работы с клиентами лучше подойдет RFM сегментация, так как она позволяет разделить клиентов на более персонализированные группы, с которыми проще и продуктивнее работать, чем с обобщенными группами на основе кластеризации.

Но если по какой-то причине кластеризация окажется предпочтительнее, можно предложить следующие методы работы с выделенными кластерами:

- Кластер 0. Рассылка с напоминаниями, скидками, подборками акционных товаров, для стимуляции повторных покупок;
- Кластер 1. Так как вернуть таких клиентов может быть проблематично и не всегда финансово обосновано, будет проще не допускать попадания новых клиентов в этот кластер. Например, ввести акционные предложения на скидку на повторную покупку, в течении ограниченного времени (2-4 месяца), или подписочную модель сотрудничества, с накопительными скидками;
- Кластер 2. Эти клиенты уже лояльные, важно не ухудшить взаимодействие с ними.

Классификация товаров

В рамках классификации товаров, вся продукция, упомянутая в датасете, была разделена на три группы:

1. Категория А - товары, приносящие 80% от общего объема выручки;
2. Категория В - товары, приносящие 15% от общего объема выручки;
3. Категория С - товары, приносящие 5% от общего объема выручки.




Рисунок 10. ABC классификация товаров

На графике можно увидеть, что товаров категории С в два раза больше, чем товаров категорий А и В, при том, что сама категория С генерирует только 5% выручки. Но так как в датасете нет данных о закупочной стоимости товаров, нельзя с уверенностью сказать, какое влияние оказывает категория С на бизнес - положительное, отрицательное, или нейтральное.

Необходимо провести подробный анализ категории С с точки зрения маржинальности. Возможно получится выявить товары, которые приносят незначительную часть прибыли, или не приносят ее вообще.

Анализ отмененных заказов




Рисунок 11. Ежемесячная доля и количество отмененных заказов

Данные об отмененных заказах коррелируют с данными о количестве успешных заказов в месяц и количестве уникальных пользователей за месяц. Можно наблюдать, что в течении года доля отмененных заказов постепенно снижается, достигая минимума в ноябре, при этом количество отмененных заказов в ноябре достигает максимума, из чего можно сделать вывод, что здесь имеет место быть классическая проблема масштабирования - чем больше заказов, тем больше отмен.




Рисунок 12. Доля отмененной выручки

При этом общая доля отмененной выручки за год довольно небольшая и составляет 2.43%, но доля отмененных заказов составляет 14.76%, что без подробного анализа отмен нельзя охарактеризовать как высокий или низкий рейтинг.




Рисунок 13. Топ отмененных товаров по количеству отмен, топ отмененных товаров по объему отмены

По количеству отмен сильно выделяется один товар: REGENCY CAKESTAND 3 TIER, он имеет наибольший разрыв с предыдущим значением, его отменили 177 раз, но при этом заказали 2198 раз.

В целом, по количеству отмен нельзя выделить явные товары аутсайдеры, так как нет данных о количестве брака товаров и причинах отмены.

Из топ 20 товаров, отмененных по объему, у 12 большая часть объема была отменена в рамках одного заказа, это позволяет выдвинуть гипотезу о том, что как минимум 50% отмененной выручки генерируется за счет отмен крупных партий.